

INFORME TP4


CLASIFICANDO INFORMALES EN LA EPH

https://github.com/Maximo8703/TP4_UBA_Grupo3

A. Enfoque de validación: 2024 como entrenamiento, 2025 como testeo

De la base inicial de los ocupados, se borraron variables por estar explicadas en otras o porque son variables categóricas que por sí solas no explican de manera significativa. Como es el caso de las variables referidas a la educación, que se resumen en *educ* y las variables de cantidad de horas trabajadas que se pueden ver en *horastrab*.

En cuanto al análisis de diferencia de medias, en todas las variables muestran un resultado muy similar, salvo en el ingreso principal. La diferencia es muy grande y en parte se debe al aumento de los salarios reales en T1 2025 respecto al año anterior. Los datos de 2024 fueron actualizados por inflación.



	Media 2024	Media 2025	Diferencia
CH04	1.469	1.467	-0.001
Edad	40.965	41.366	0.400
CAT_OCUP	2.716	2.701	-0.014
Nª Trab	5.227	5.121	-0.106
ING. PRINC.	465987.549	716453.336	250465.788
educ	11.672	11.803	0.131
horastrab	34.785	34.953	0.168
nhogar	5.040	4.969	-0.071

B. Modelo de Regresión Logística: extensión el trabajo de Maurizio & Monsalvo


Para el primer modelo se usaron las bases de ocupados_X_2024 e y_2024 con 14.910 muestras, mientras que para el segundo se usó la base de ocupados_X_2025_MM e y_2025 con 4.074 muestras. Para ambos casos se usó el 30% de la muestra para testeo. Cabe destacar que para que la variable de ingreso principal no sea sobreestimada con respecto al resto, ambos datasets fueron escalados de la misma manera que se realiza en PCA, a cada muestra se le restó la media para luego dividirlo por el desvío. Se obtuvieron los resultados a continuación:

	Variable	Coef. #1	Std. Error #1	Odds Ratio #1	Coef. #2	Std. Error #2	Odds Ratio #2
0	CAT_OCUP	-2.46	0.05	0.09	-2.00	0.10	0.13
1	CH04	-0.08	0.03	0.93	0.07	0.06	1.07
2	Edad	-0.07	0.03	0.93	0.03	0.06	1.03
3	INFORMAL/FORMAL_x	NaN	NaN	NaN	1.20	0.08	3.30
4	ING. PRINC.	-0.30	0.04	0.74	-0.14	0.07	0.87
5	Nª Trab	0.02	0.03	1.02	0.09	0.07	1.09
6	educ	-0.44	0.03	0.64	-0.39	0.07	0.67
7	horastrab	0.04	0.03	1.04	0.08	0.09	1.08
8	nhogar	0.01	0.03	1.01	-0.01	0.06	0.99

Nota: el criterio de informalidad es el informal self-employed que abarca propietarios de empresas con hasta cinco empleados, trabajadores por cuenta propia no profesionales y trabajadores familiares no remunerados.


Como los datos están escalados, los odds ratio hay que interpretarlos como desvíos estándar. Por ejemplo, si el desvío estándar para edad es 10 y el odds ratio es igual a 0.93, se interpreta que un aumento de 10 años disminuye las odds de ser informal en un 7%. Se puede destacar para ambos modelos una fuerte importancia de la categoría ocupacional, haciendo referencia a que siendo empleado o cuentapropista se tienen menos chances de ser informal. Los segundos coeficientes en importancia son el ingreso principal y los años de educación, donde de forma lógica, cuanto mayores sean los predictores, menos probabilidades hay de ser informal. La diferencia entre un modelo y otro radica en la diferencia entre los desvíos estándar, donde son mayores en el segundo modelo (0.03 vs 0.06). El objetivo de calcular modelos diferentes era saber si agregar la columna de informalidad de 1T 2024 iba a afectar a los coeficientes de edad y educ, se obtuvo como resultado únicamente la modificación significativa de la variable edad, donde hubo en cambio de signo, en el segundo modelo se ve que cuanto mayor es la edad, más probabilidad hay de ser informal.

Respecto a la probabilidad de ser informal, decidí compararlo con el ingreso principal ya que es la variable con mayor distribución de frecuencia, y viendo el gráfico, hay una relación lineal decreciente entre informalidad e ingreso.




C. Desempeño del modelo y predicción afuera de la muestra

Ambos modelos tuvieron un muy buen desempeño a la hora de predecir las observaciones, con métricas muy similares.



Ambos casos tuvieron un porcentaje muy pequeño de falsos informales (false positives), y destacan por el accuracy (0.943 y 0.905) y por el AUC-ROC (0.962 Y 0.982). El segundo modelo es peor para predecir informales, con un 70% de informales observados predichos correctamente, contra un 80% del primer modelo

Las trayectorias de las curvas se aproximan al vértice superior izquierdo del cuadrante, lo que demuestra que los modelos alcanzan tasas elevadas de verdaderos positivos tolerando niveles marginales de falsos positivos. En toda la curva el segundo modelo predice mejor que el primero, que se puede atribuir a la presencia de la columna de informalidad del 1T 2024.



Para responder a la Secretaría de Trabajo, el modelo 2 (2025) es la mejor opción porque predice mejor los casos, algo que se refleja en su AUC de 0.982. En este caso, es importante evitar los falsos positivos, porque implicaría destinar fondos de formalización a personas que ya son formales. En ese punto, el modelo 2 funciona mucho mejor, ya que solo comete 3 errores de este tipo frente a los 23 del modelo 1. Que, si bien el tamaño de las muestras es distinto, en porcentaje el modelo 2 performa mejor. El segundo modelo logra que el presupuesto llegue de manera más eficiente a la población que realmente lo necesita.

D. Herramientas de IA y reflexión final.

La inteligencia artificial fue una herramienta de apoyo durante el desarrollo del trabajo, especialmente en aspectos vinculados a programación y presentación de resultados. En primer lugar, me ayudó en la realización y corrección de código en Python, también resultó útil para el emprolijamiento de gráficos y tablas, facilitando una presentación más clara y ordenada de los resultados obtenidos. En relación con los modelos econométricos, la IA me asistió para continuar con el desarrollo de las regresiones logísticas. En el notebook de clase habíamos trabajado este tipo de modelos utilizando la librería scikit-learn, mientras que en este trabajo utilicé statsmodels, por lo que necesité adaptar el desarrollo del TP. Además, fue de ayuda al momento de realizar los inner join entre bases de datos, especialmente en el segundo modelo, y para configurar correctamente la tabla comparativa de resultados, ya que ambos modelos contaban con distinta cantidad de variables explicativas X.

El TP fue realizado aproximadamente en 12 horas

